DLHLP HW2 Voice Conversion Report

組長 github id: ming024
組員：r08922080 資工碩一 簡仲明
r08921062 電機碩一 黃健祐
b04501127 土木四　凌于凱

HW2-1 (Auto-Encoder) (2.5%)

(1) 請以 Auto-Encoder 之方法實做 Voice conversion。如果同學不想重新刻一個 auto-encoder，可以試著利用這個repo的部分程式碼，達到實現出 auto-encoder。如果你是修改助教提供的 repo，請在 report 當中敘述你是如何更改原本程式碼，建議可以附上修改部分的截圖以利助教批閱；同時，如果各位有更動原本模型參數也請一併列出。如果你的 auto-encoder是自己刻的，那也請你簡單敘述你的實作方法，並附上對應程式碼的截圖。(1%)

./hps/vctk.json：把train encoder跟decoder的step改成100000，其他改成0

```
21      "enc_pretrain_iters": 100000,
22      "dis_pretrain_iters": 0,
23      "patch_iters": 0,
24      "iters": 0
```

./hps/en_speaker_used.txt

```
1  1
2  2
```

./main.py：把不是train encoder跟decoder的地方註解掉（39、40、41行）

```
38          solver.train(args.output_model_path, args.flag, mode='pretrain_G')
39          #solver.train(args.output_model_path, args.flag, mode='pretrain_D')
40          #solver.train(args.output_model_path, args.flag, mode='train')
41          #solver.train(args.output_model_path, args.flag, mode='patchGAN')
```

./solver.py：新增178、179兩行

```
175                     if iteration % 100 == 0:
176                         for tag, value in info.items():
177                             self.logger.scalar_summary(tag, value, iteration + 1)
178                     if iteration % 1000 == 0 or iteration + 1 == hps.iters:
179                         self.save_model(model_path, iteration)
```

(2) 在訓練完成後，試著將助教要求轉換的音檔轉成 source speaker 和 target speaker 的 interpolation，也就是在 testing 的時候，除了將指定的音檔轉成 p1 和 p2 的聲音之外，請嘗試轉成p1 和 p2 interpolation 的聲音。並比較分析 interpolated 的聲音和 p1 以及 p2 的關係。你可以從聲音頻率的高低、口音、語調等面向進行觀察。只要有合理分析助教就會給分。請同時將這題的音檔放在github 的 hw2-1資料夾中，檔名格式請參考投影片。(1.5%)

做法：

將decoder裡面的五個emb layer個別用[0]以及[1]當input，將兩emb output取平均，再個別放回原本的layer input。

分析：

字詞前面p1_p2_inter比較接近p1的聲音，而p2_p1_inter則比較接近p2的聲音，兩種字詞後面都含有對方的音調，但成份較小，猜測可能是content encoder還有保留一些speaker information，導致與embedding的平均合起來，source的聲音比較明顯，而兩者中間值的聲音在斷詞原本聲音成份較小的地方才顯示出來。

HW2-2 (GAN) (2.5%)

(1) 請使用助教在投影片中提到的連結，進行 voice conversion。請描述在這個程式碼中，語者資訊是如何被嵌入模型中的？請問這樣的方式有什麼優缺點？有沒有其他的作法可以將 speaker information 放入generator 裡呢？(1%)

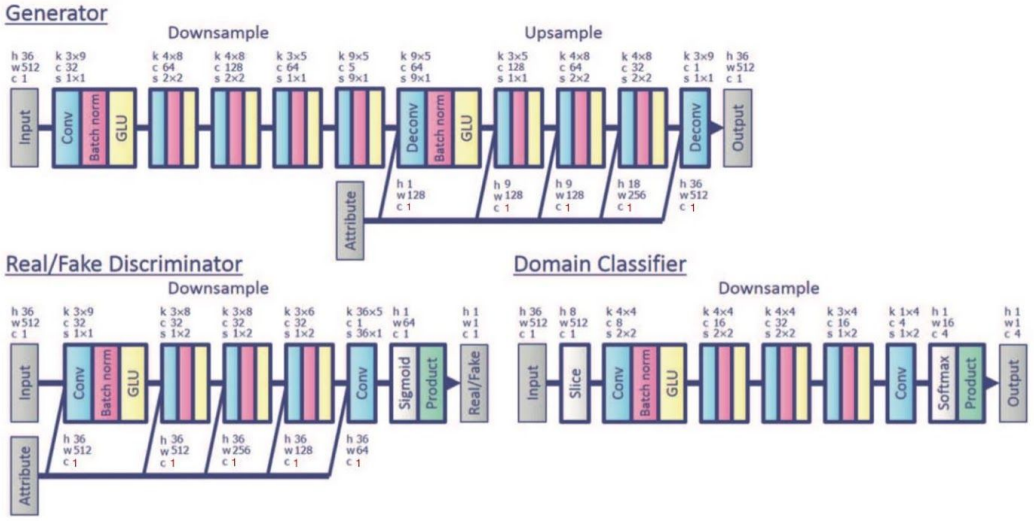

將語者資訊c(one hot encoding) 在feature與time的方向repeat成與input相同，再把它與input 延channel dimension的方向串接起來。
這樣做法實做起來容易，但參數量與語者數量成正比，語者越多，則model參數量會變多，因為每個convolution layer的filter要多出語者數量的維度。
可以將c通過speaker embedding layer，然後將hidden layer拿出來跟其做inner product，再與conv的input concat，這樣參數量就固定，不會隨語者數量而變化。

(2) 請描述你如何將原本的程式碼改成訓練兩個語者的 voice conversion 程式。(0.5%)

因為speaker information變成[0]或[1]，而不是大小為4的one hot encoding，因此需要修改model會用到speaker information的地方。

./model.py

```
65          self.up1 = Up2d(6, 64, (9,5), (9,1), (0,2))
66          self.up2 = Up2d(65, 128, (3,5), (1,1), (1,2))
67          self.up3 = Up2d(129, 64, (4,8), (2,2), (1,3))
68          self.up4 = Up2d(65, 32, (4,8), (2,2), (1,3))
69
70          self.deconv = nn.ConvTranspose2d(33, 1, (3,9), (1,1), (1,4))
```

```
103         self.d1 = Down2d(2, 32, (3,9), (1,1), (1,4))
104         self.d2 = Down2d(33, 32, (3,8), (1,2), (1,3))
105         self.d3 = Down2d(33, 32, (3,8), (1,2), (1,3))
106         self.d4 = Down2d(33, 32, (3,6), (1,2), (1,2))
107
108         self.conv = nn.Conv2d(33, 1, (36,5), (36,1), (0,2))
```

(3) 請問這個程式碼中，input acoustic feature 以及 generator output 分別是什麼呢？ (1%) Hint: 請研究一下 preprocess 時做了哪些事情。
input acoustic feature 使用 WORLD 所計算的 mel-cepstral coefficients (fundamental frequency(F0), code spectral envelop(sp), Aperiodic parameter(ap))，generator input 為512個frame的spectral envelop，output亦為如此，最後會將這些sp decode，並將F0 mean和std轉換到所需要target的f0 mean和std，最後在將decoded sp、converted f0、ap 用WORLD做synthesize成最後的輸出的音檔。

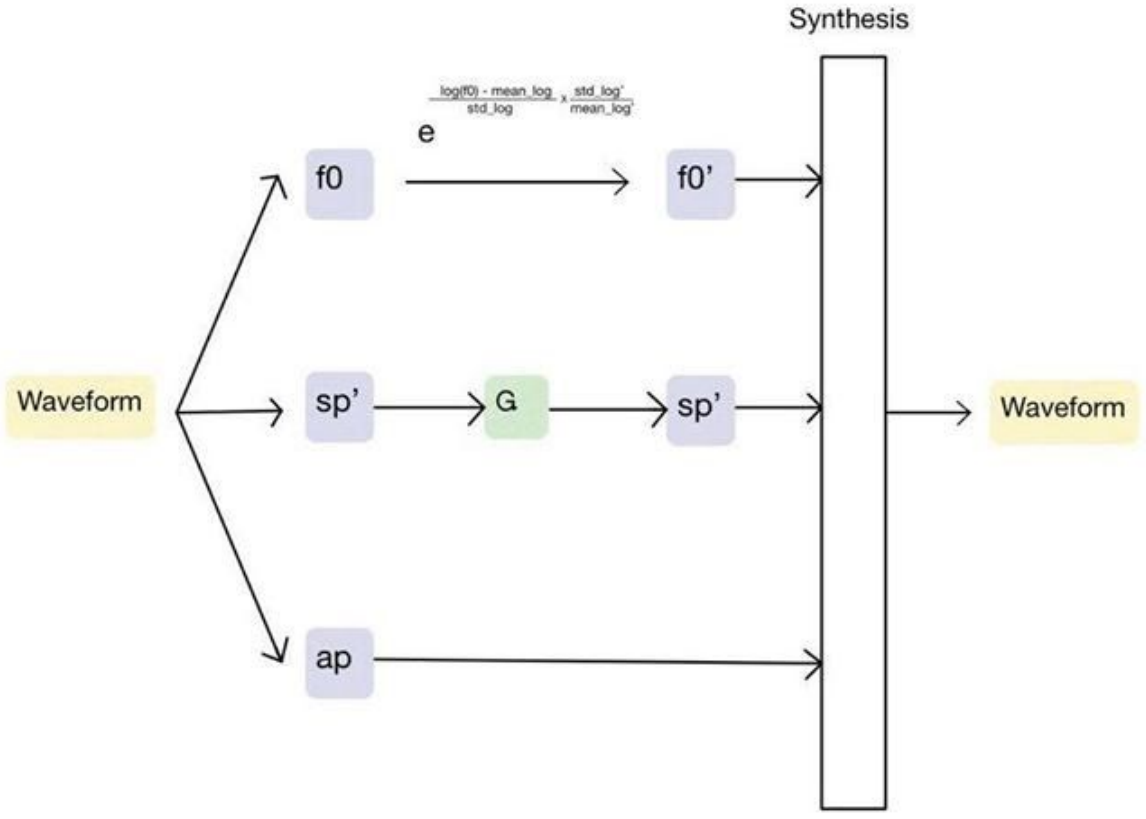

HW2-3 (1) 和 (2) 擇一回答 (4%)

(1) 請自己找一個不是 StarGAN-VC，也不是 HW2-1 的 model，實際 train 看看。請詳細描述 model 得架構， training objective，訓練時是否需要 paired data 等等。(4%) Hint: useful link

AutoVC(https://arxiv.org/abs/1905.05879): 使用 AutoVC 作者提供的 code，然後我們有稍微修改，vocoder 是用 universal vocoding (https://github.com/bshall/UniversalVocoding)

模型架構：

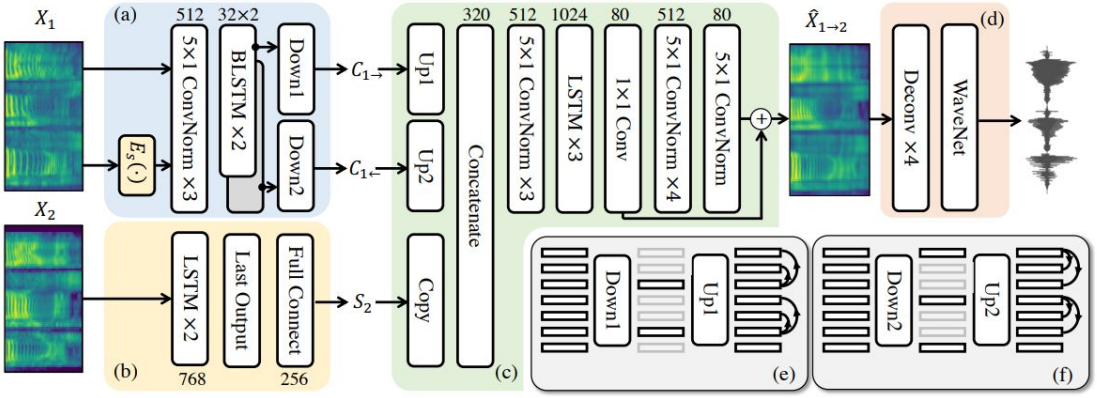

(a) Content Encoder $E_c(.)$ ，input為80維的mel-spectrongram，和speaker enbedding 串接，經過三層有batch normalization的conv layer，以及Relu activation，再用兩個BLSTM產生兩個32維的output(forward和backward)，將其downsample，forward取time steps={0, 32, 63...}，backward取{31, 62,...}，成$C_{1->}$和$C_{1<-}$。

(b) Speaker Encoder $E_s(.)$，使用pre-trained d-vector

(c) Decoder，將$C_{1->}$和$C_{1<-}$ upsample，與speaker embedding concat，經過三層有batch normalization的conv layer，以及Relu activation，以及三層LSTM，再利用1 x 1 conv layer project 到 80 維成

$$\tilde{X}_{1\rightarrow 2}$$

最後使用post-network，由五層conv layer組成，最後一層降維至80維，output 為 residual signal，final conversion為

$$\hat{X}_{1\rightarrow 2} = \tilde{X}_{1\rightarrow 2} + R_{1\rightarrow 2}$$

(d) Spectrogram inverter，使用univeral vocoding

training data:
hw2-1 unpaired data (90% train, 10% val) --> 80-dimensional mel spectrogram

training objective:

$$\min_{E_c(\cdot),D(\cdot,\cdot)} L = L_{\text{recon}} + \mu L_{\text{recon0}} + \lambda L_{\text{content}}$$

$$L_{\text{recon0}} = \mathbb{E}[\|\tilde{X}_{1\to1} - X_1\|_2^2]$$

$$L_{\text{recon}} = \mathbb{E}[\|\hat{X}_{1\to1} - X_1\|_2^2]$$

$$L_{\text{content}} = \mathbb{E}[\|E_c(\hat{X}_{1\to1}) - C_1\|_1]$$

訓練50萬epoch，最後 Lrecon、Lrecon0 、Lcontent收斂至0.0004、0.0003、0.0001

<u>成果比較:</u>

因為使用不同的 vocoder 的關係，AutoVC的結果比較少機械音的情況，且聲音比較接近真正對方的聲音，而不像hw2-1的結果只聽出來是男轉女或女轉男；因為使用pre-trained d-vector，所以可以轉換unseen speaker；但在content的部份，感覺有一些短音被丟掉，造成有些詞有點連起來，猜測可能是中間content encoder output的元素太少，導致表達content的成份不夠所導致，或是因為只使用hw2-1的data，資料量太少導致，但因為時間的緣故，沒有實際更動再train一次，可能之後在分享會時分享是否為這些原因導致。